健康行为与成人自报糖尿病状态的关联及分类

基于 BRFSS 2015 调查数据

李则奇

学号　2611210110

2026 年 11 月

摘要

本研究考察健康行为与成人自报糖尿病状态的关联，以及行为信息在基本人口学信息之外的分类增量价值。使用美国疾病控制与预防中心（CDC）公开发布的 2015 年行为危险因素监测系统（BRFSS）原始数据，依据官方问卷编码构建结局与特征。原始样本包含 441,456 条记录，主分析纳入 307,683 名信息完整的受访者，其中 40,621 人自报曾被告知患有糖尿病，加权比例为 10.89%。

使用调查权重拟合多因素 Logistic 回归，并按分层和初级抽样单位计算稳健标准误。分类实验按 60%、20%、20% 分为训练、验证和测试集，对人口学 Logistic 回归、人口学与行为 Logistic 回归、梯度提升模型进行比较。无休闲体力活动与更高的糖尿病优势相关，调整后 OR 为 1.427（1.358—1.500）。加入行为变量后，测试集 ROC-AUC 从 0.776 升至 0.784，平均精确率从 0.260 升至 0.278。AUC 差值为 0.0076，测试集配对 Bootstrap 百分位区间为 0.0048 至 0.0106。

健康行为在基本人口学信息之外提供了小幅分类增益。运动与饮食指标适合用于描述健康状态差异。横断面问卷同时受到确诊后行为改变、未诊断疾病及缺失回答选择的影响，结果应结合这些因素解释。

关键词　BRFSS；健康行为；糖尿病；调查权重；Logistic 回归

1　研究背景与问题

BRFSS 通过固定电话和移动电话收集成年人的健康行为、健康状况及医疗服务相关信息。2015 年公开数据覆盖美国 50 个州、哥伦比亚特区、关岛和波多黎各，包含饮食、吸烟、饮酒及体力活动指标，适合开展本研究的变量组合分析 [1]。

本研究提出两个相互关联的问题。第一，在控制年龄、性别、教育和家庭收入后，不同健康行为与自报糖尿病状态有何关联？第二，在相同训练及测试样本下，加入健康行为能否提高分类表现？前者使用调整后优势比及置信区间刻画关联，后者通过测试集指标评价增量信息。选择 2015 年是因为该年度同时包含本研究所需的运动、吸烟、饮酒与饮食问卷。本文结果描述该年度的调查情境。

2　数据来源与研究样本

2.1　原始文件与结局定义

从 CDC 官方年度页面下载 SAS Transport 压缩文件 LLCP2015XPT.zip，用 Python 的 pandas.read_sas 分块读取并提取 17 个分析及抽样设计字段。保留原始压缩包、变量字典、抽样字段和文件 SHA-256 摘要，建立数据来源记录。全文件读取行数与官方公布的 441,456 条一致。

结局取自 DIABETE3，题意为“是否曾被告知患有糖尿病”。编码 1 为阳性，编码 3 为阴性。编码 2 表示仅妊娠期间被告知糖尿病，编码 4 表示糖尿病前期或临界状态，均排除于主分析。编码 7、9 和空值分别涉及不确定、拒答或缺失，作为结局不明排除。该定义保留了问卷的自报诊断性质，包含糖尿病类型未进一步细分的回答 [2]。

筛选阶段	保留人数
原始调查记录	441,456
排除仅妊娠期糖尿病	−3,608
排除前期或临界状态	−7,690
排除结局不明	−798
结局明确且权重有效	429,360
排除任一主分析特征缺失	−121,677
最终完整案例	307,683

2.2 变量构建

年龄、教育和收入均按分类变量处理，避免把类别编号当作等距连续值。吸烟分为每日、偶尔、曾吸烟和从未吸烟四类。“曾吸烟”以问卷累计吸烟及当前状态构造。水果指标包括问卷计算变量中的果汁等构成，频次只反映摄入频率。运动指过去 30 天工作之外的体力活动。重度饮酒采用官方性别相关阈值，成年男性每周超过 14 杯、成年女性超过 7 杯。各变量的特殊缺失码按照字典转为空值。

变量	原字段	处理
年龄	_AGEG5YR	1—13 级，14 转缺失
性别	SEX	1 男，2 女
教育	EDUCA	保留 1—6 级
家庭收入	INCOME2	保留 1—8 级
吸烟	_SMOKER3	保留 1—4 级
休闲体力活动	_TOTINDA	1 有，2 无
水果/蔬菜频次	_FRTLT1 / _VEGLT1	1 每日 ≥1 次，2 不足 1 次
重度饮酒	_RFDRHV5	1 否，2 是
BMI（扩展分析）	_BMI5	原值除以 100

3 数据质量与描述性分析

3.1 缺失处理与样本构成

主分析采用完整案例策略，排除 9 项人口学或行为特征中任意一项没有有效回答的记录。水果及蔬菜还依据官方排除标记去除超出可接受范围的回答。缺失率的分母为结局

明确的 429,360 条记录，各变量缺失可重叠，因此缺失数不能直接相加。年龄和收入区间按类别保留，极端 BMI 值保留官方清理后的数值，BMI 只用于扩展模型。

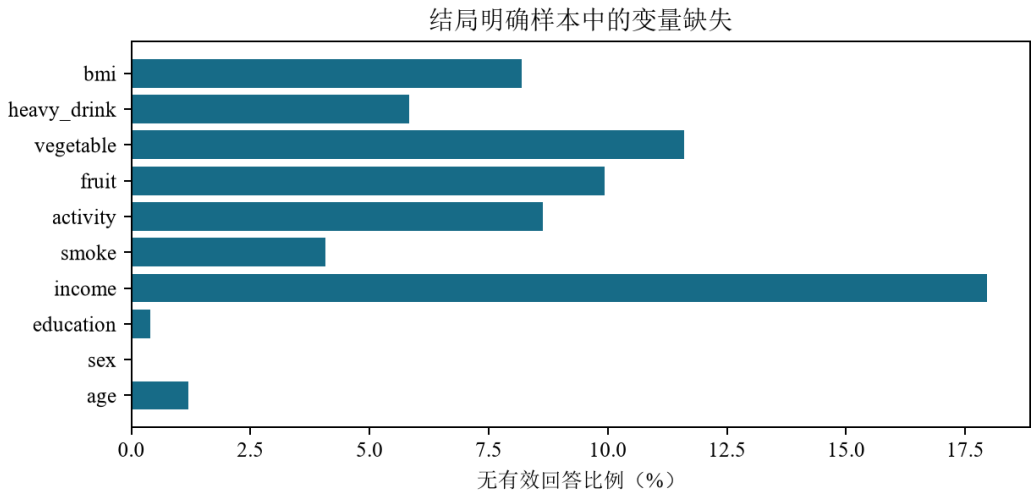


图 1: 结局明确样本中的无有效回答比例。缺失包括拒答、不确定、未询问及无效范围标记。

最终保留结局明确样本的 71.66%。收入无有效回答占 17.96%，蔬菜频次占 11.60%，水果频次占 9.94%，是主要的样本损失来源。纳入样本的加权糖尿病比例为 10.89%，被排除的结局明确样本为 10.51%。两者结局比例较接近，但这项比较不能排除行为分布与关联结构上的选择差异。

3.2 年龄分布与疾病状态

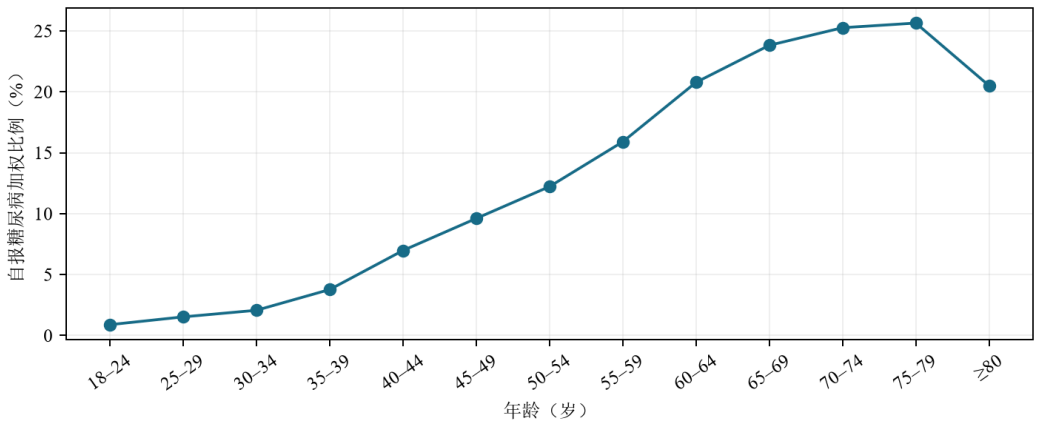


图 2: 完整案例样本不同年龄组的自报糖尿病加权比例。

糖尿病状态随年龄呈明显差异，较高年龄组的比例较高，最高年龄组出现回落。该形态涉及出生队列、诊断机会及存活选择等因素，年龄分组因此作为所有模型的基本特征。

4 统计分析与分类实验设计

4.1 加权关联模型

描述性比例及关联模型使用最终调查权重 _LLCPWT。回归包含年龄、性别、教育、收入和全部 5 类健康行为。分类特征采用虚拟变量编码，第一有效类别作为参照。人口学参照分别为 18—24 岁、男性、教育第 1 级及收入第 1 级。吸烟参照为每日吸烟，其他二分类参照依次为有运动、每日水果至少一次、每日蔬菜至少一次、非重度饮酒。

设 p_i 为个体的拟合阳性概率，x_i 为特征向量，w_i 为均值标准化后的调查权重。使用加权二项对数似然估计系数，优势比为 $\exp(\beta)$。实现中采用 $C = 10^8$ 的极弱正则近似无惩罚 Logistic 回归。标准误使用抽样分层 _STSTR 和初级抽样单位 _PSU，与州编码共同构建唯一键。以分层内 PSU 得分总和形成夹心协方差，使用有放回近似，未使用有限总体修正。样本域外记录在得分中置零，本次未发现单 PSU 分层。95% 区间采用正态近似。

$$A = \sum_i w_i p_i (1 - p_i) x_i x_i^\top, \quad \widehat{V} = A^{-1} \left[\sum_h \frac{m_h}{m_h - 1} \sum_j (U_{hj} - \bar{U}_h)(U_{hj} - \bar{U}_h)^\top \right] A^{-1}.$$

其中 U_{hj} 为分层 h 内 PSU j 的加权得分总和，m_h 为 PSU 数。完整案例域的权重未经缺失选择再校准。

4.2 分类实验与阈值选择

以固定随机种子 20261108，按结局分层划分训练集、验证集和测试集。三个模型使用完全相同的样本划分。人口学 LR 包含 4 项基础变量，人口学与行为 LR 加入 5 类行为变量，梯度提升使用相同的 9 项特征。独热编码仅在训练集拟合。预测模型训练时同样使用均值标准化调查权重，保持调查中的阳性比例。

数据集	人数	用途
训练集	184,609	模型参数与编码拟合
验证集	61,537	选择约登指数最大阈值
测试集	61,537	固定模型的最终评价

LR 采用 $C = 1$、最多 800 次迭代。梯度提升固定 120 轮、每棵树最多 15 个叶节点、L2 正则系数 10，关闭内部提前停止。超参数预先固定，没有搜索测试集最优组合。每个模型在验证集上选择灵敏度与特异度之和最大的阈值，再应用于测试集。

全部评价指标使用测试集调查权重，包括 ROC-AUC、平均精确率 AP、Brier 分数、灵敏度、特异度与阳性预测值。AP 按平均精确率定义计算。配对 Bootstrap 在同一批测试记录上重抽 150 次，计算加入行为后的 AUC 差值，以 2.5 和 97.5 百分位表示区间。这一区间描述测试样本重抽稳定性，未模拟复杂抽样设计。

5 结果

5.1 健康行为的调整后关联

比较	调整后 OR（95% CI）
偶尔吸烟 / 每日吸烟	1.151（1.007—1.315）
曾吸烟 / 每日吸烟	1.457（1.346—1.578）
从未吸烟 / 每日吸烟	1.205（1.114—1.303）
无运动 / 有运动	1.427（1.358—1.500）
水果不足每日一次 / 至少一次	1.118（1.063—1.175）
蔬菜不足每日一次 / 至少一次	1.095（1.034—1.160）
重度饮酒 / 非重度饮酒	0.467（0.403—0.541）

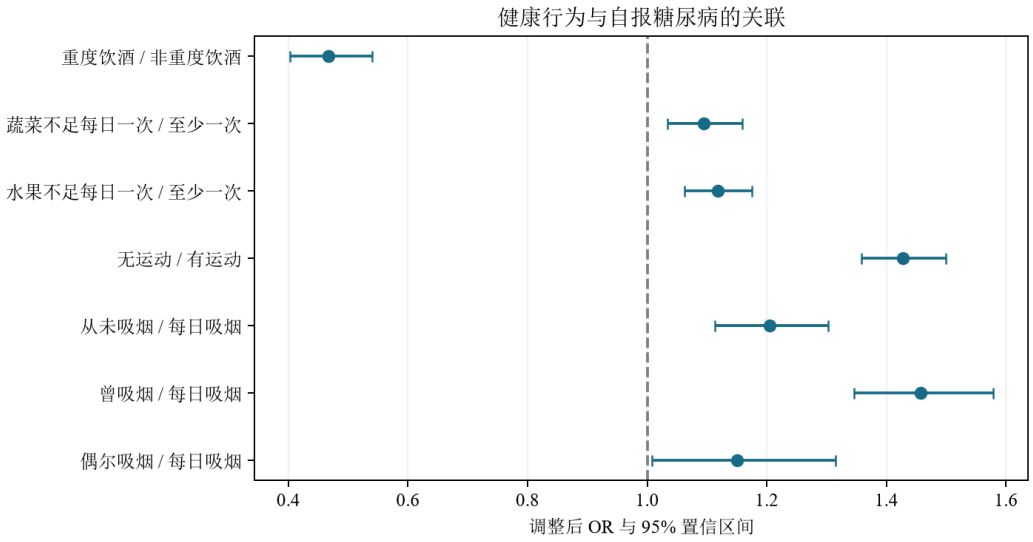


图 3: 同时控制人口学变量及其余行为变量后的关联。区间使用分层 PSU 稳健标准误。

无休闲运动者的调整后 OR 为 1.427，水果和蔬菜摄入不足每日一次的 OR 分别为 1.118 和 1.095。运动指标对应的关联幅度较大。吸烟类别相对于每日吸烟者呈现更高的糖尿病优势，重度饮酒类别则呈较低优势。这些方向需要结合诊断后的戒烟、减少饮酒、疾病类型混合及残余混杂理解。调查记录的是当前或近期行为与既往确诊状态的组合，不能直接据此判断改变某项行为的干预效果。

5.2 BMI 扩展分析

BMI 完整子样本为 295,254 人。为控制额外样本剔除的影响，在该同一子样本中分别拟合含 BMI 与不含 BMI 的模型。BMI 以每增加 5 单位进入模型。以下展示运动及饮食变量的比较，完整系数保存于结果 CSV。

比较	同子样本未加 BMI 的 OR	加入 BMI 后的 OR
无运动 / 有运动	1.428	1.240
水果不足每日一次 / 至少一次	1.124	1.065
蔬菜不足每日一次 / 至少一次	1.085	1.092

加入 BMI 后，无运动的 OR 为 1.240（1.176—1.307）。BMI 每增加 5 单位的 OR 为 1.521（1.493—1.551）。BMI 可能与行为及疾病状态同时相关，此扩展分析反映调整变量集合变化后的关联敏感性。

5.3 分类模型的测试集表现

模型	ROC-AUC	AP	Brier
人口学 LR	0.7763	0.2600	0.0856
人口学与行为 LR	0.7839	0.2776	0.0847
人口学与行为梯度提升	0.7838	0.2726	0.0848

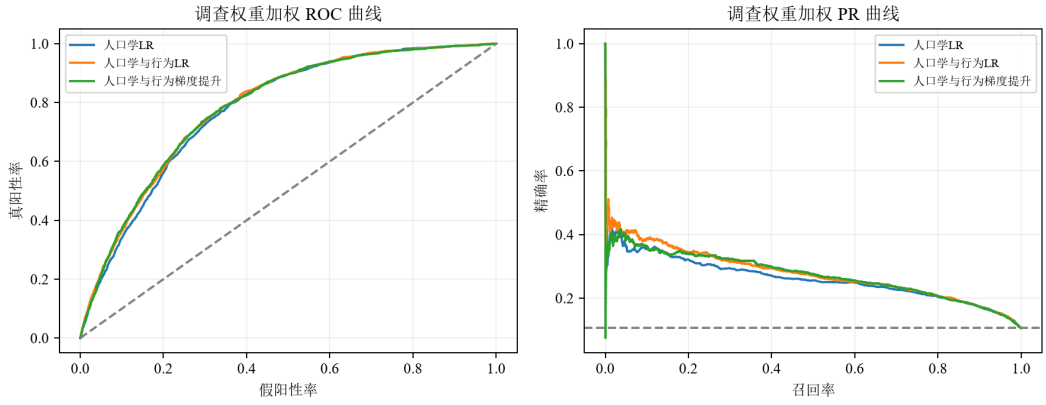


图 4: 同一测试集上的加权 ROC 及 PR 曲线。PR 虚线为测试集加权阳性比例。

行为 LR 相对于人口学 LR 的 AUC 提升为 0.0076，Bootstrap 区间为 0.0048 至 0.0106。AP 提高 0.0176，Brier 分数降低 0.0009。三项指标一致支持行为信息带来增量，但绝对改善较小。梯度提升的 AUC 与行为 LR 接近，AP 略低，在本次固定参数实验中没有明显额外优势。

验证集选择的阈值约为 0.11—0.13，低于常用的 0.5。这反映了样本阳性比例与本实验灵敏度、特异度平衡准则的共同作用。阈值比较用于评价模型的分类行为。

模型	阈值	灵敏度	特异度	阳性预测值
人口学 LR	0.115	0.778	0.651	0.209
行为 LR	0.115	0.781	0.659	0.214
梯度提升	0.127	0.738	0.702	0.227

行为 LR 的灵敏度为 78.1%，特异度为 65.9%，阳性预测值为 21.4%。在此阈值下，模型标记为阳性者中大部分实际属于自报阴性，说明仅依靠这组问卷信息进行个体分类仍有较多误报。

5.4 概率校准

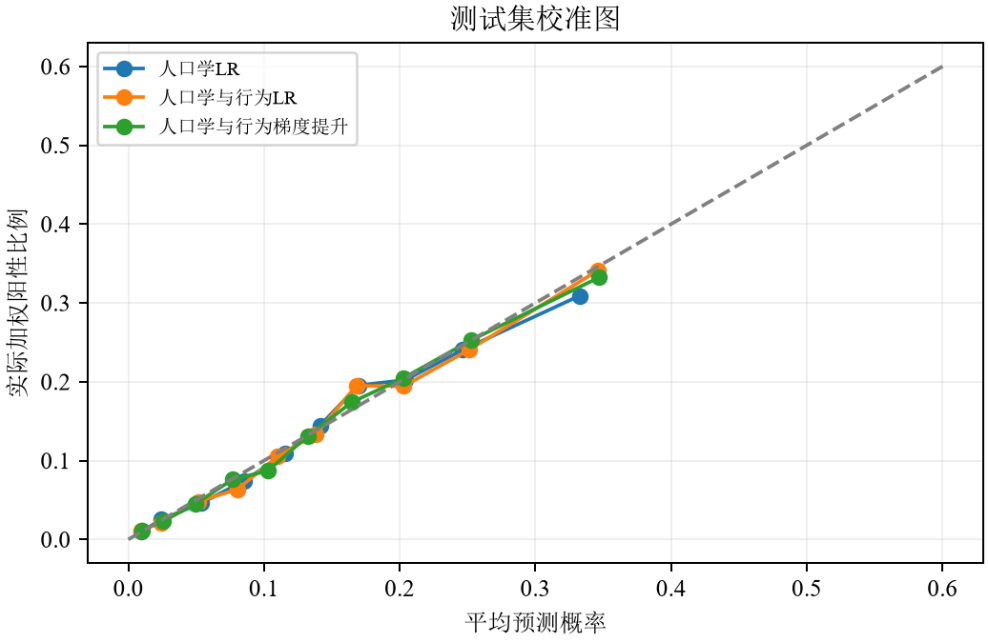


图 5: 按各模型预测概率的样本十分位分组，比较组内加权预测概率与加权实际阳性比例。

校准图展示模型输出概率与观察比例的一致性。对角线表示两者相等。分组点受分箱方式及高概率组样本量影响，因此与 Brier 分数结合评估。本次未使用验证集再次校准概率，图中展示原始模型输出。

6 讨论

6.1 关联强度与预测增益

调整后关联和分类增量回答不同问题。运动及饮食变量可以呈现清楚的组间关联，但年龄、收入等基础变量已经提供较强区分信息。加入行为后 AUC 仅增加约 0.008，表明这组粗粒度行为指标所增加的信息有限。AP 与 Brier 分数的同步改善说明增益并非只出现在单一评价指标上。

6.2 行为变量的解释

糖尿病诊断可能促使受访者调整饮食、运动、吸烟和饮酒。行为问卷的测量期与“曾被告知糖尿病”的时间范围并不相同。已患病者的健康行为变化会影响观察到的横断面关联。吸烟和饮酒的反向关系应视为这一设计下的经验发现，并结合体重、其他疾病、诊断机会和未测量因素理解。数据没有在本研究结局中细分糖尿病类型，也没有通过统一血糖检查识别未诊断糖尿病。

6.3 样本选择与可推广性

完整案例策略损失约 28% 的结局明确记录，收入缺失贡献较大。调查权重纠正了原调查部分抽样与响应差异，但不能自动消除本研究完整案例筛选产生的选择偏差。后续可比较多重插补及缺失类别策略，并在新的调查年份验证模型。本文的随机拆分评价属于同一年度样本内部验证，其性能不能直接外推到其他年份或中国人群。BMI 扩展模型采用线性项，进一步研究可用样条描述非线性。

7 结论

在 BRFSS 2015 完整案例样本中，缺乏休闲体力活动、较低的水果与蔬菜摄入频次与较高的自报糖尿病优势相关。在人口学变量之外加入行为指标，改善了加权 ROC-AUC、AP 及 Brier 分数，但增量幅度较小。梯度提升模型在本次参数设置下与行为 Logistic 回归表现接近。结果支持在报告中同时呈现关联估计、分类性能、概率校准和误报代价，并根据横断面测量及缺失选择的特点解释发现。

8 数据与代码可用性

analyze.py 执行完整分析，build_report.py 读取结果生成 LaTeX 报告。data 保留原始数据及分析样本，results 保存关联系数、评价指标、样本划分和测试集预测。随机种子、文件哈希、软件版本及运行命令记录于项目文档。

参考文献

[1] Centers for Disease Control and Prevention. 2015 BRFSS Survey Data and Documentation. https://www.cdc.gov/brfss/annual_data/annual_2015.html. 访问日期 2026 年 11 月 8 日.

[2] Centers for Disease Control and Prevention. BRFSS 2015 Codebook Report. https://www.cdc.gov/brfss/annual_data/2015/pdf/codebook15_llcp.pdf.

[3] Centers for Disease Control and Prevention. BRFSS 2015 Summary Matrix of Calculated Variables. https://www.cdc.gov/brfss/annual_data/2015/summary_matrix_15_version12.html.