健康行为与成人自报糖尿病状态的关联及分类

基于 BRFSS 2015 的横断面分析

李则奇

学号　2611210110

2026 年 11 月

摘要

目的　估计成人健康行为与自报糖尿病状态的关联，量化行为指标在基础人口学信息之外的分类增益。

方法　对美国行为危险因素监测系统（BRFSS）2015 年数据开展横断面分析。采用复杂抽样加权 Logistic 回归估计调整后优势比（OR）及 95% 置信区间（CI）。按结局分层划分训练、验证和测试集，比较人口学 Logistic 回归、纳入健康行为的 Logistic 回归及梯度提升模型。

结果　纳入 307,683 名受访者，其中 40,621 人自报糖尿病，加权比例为 10.89%。无休闲体力活动的调整后 OR 为 1.427（1.358—1.500）。加入行为指标后，测试集受试者工作特征曲线下面积（ROC-AUC）从 0.7763 升至 0.7839，差值为 0.0076（配对 Bootstrap 百分位区间 0.0048 至 0.0106）。平均精确率由 0.2600 升至 0.2776。

结论　无休闲体力活动和较低的果蔬摄入频次与更高的自报糖尿病优势相关。所纳入的行为指标在人口学模型基础上带来小幅分类增益。

关键词　BRFSS；健康行为；糖尿病；复杂抽样；Logistic 回归

1　引言

前瞻性研究发现，体力活动水平与后续 2 型糖尿病发病相关[1]。人群横断面调查可刻画自报确诊者和未报告确诊者的行为分布，并评估这些行为在基础人口学信息之外提供的分类信息。

BRFSS 通过固定电话和移动电话收集成年人的健康行为、疾病状态及卫生服务信息[2, 3]。2015 年问卷同时覆盖运动、吸烟、饮酒和饮食，为比较五类行为提供了共同的调查样本。本研究估计各行为指标与自报糖尿病状态的调整后关联，并在同一测试集中比较纳入行为指标前后的分类表现。

2　资料与方法

2.1　研究设计与数据来源

本研究使用美国疾病控制与预防中心（CDC）发布的 BRFSS 2015 公开数据开展横断面二次分析。该年调查覆盖美国 50 个州、哥伦比亚特区、关岛和波多黎各。使用 Python 分块读取 CDC 发布的 SAS Transport 文件，从 441,456 条调查记录提取 17 个分析及抽样设计字段。报告结构参照 STROBE 横断面研究条目，模型开发与评价参照 TRIPOD+AI 的相关报告条目[4, 5]。

2.2　研究对象与结局

结局取自 DIABETE3，即受访者是否曾被告知患有糖尿病。编码 1 为自报确诊，编码 3 为未报告确诊。仅妊娠期间糖尿病、糖尿病前期或临界状态，以及不确定、拒答或缺失记录不纳入二分类分析[6]。主分析要求结局明确、权重有效且全部 9 项特征有效。样本筛选见表 1。

表 1　研究样本筛选过程

筛选步骤	记录数
原始调查记录	441,456
排除仅妊娠期糖尿病	−3,608
排除糖尿病前期或临界状态	−7,690
排除结局不明或权重无效	−798
结局明确且权重有效	429,360
排除主分析特征缺失	−121,677
纳入完整案例分析	307,683

注：负值为该步骤排除的记录数，其余为当步保留数。

2.3　变量定义与缺失处理

人口学特征包括年龄组、性别、教育和家庭收入。健康行为包括吸烟、休闲体力活动、水果频次、蔬菜频次和重度饮酒。休闲体力活动指调查前 30 天工作以外的运动或体力活动。水果频次包含问卷定义的果汁摄入。按 CDC 计算变量的定义，成年男性每周超过 14 杯或成年女性每周超过 7 杯归为重度饮酒[7]。

表 2　分析变量及编码

变量	BRFSS 字段	分析编码
年龄	_AGEG5YR	18 至 24 岁为第一组，此后按 5 岁分组，80 岁及以上合并
性别	SEX	男、女
教育	EDUCA	按原问卷保留 6 类
家庭收入	INCOME2	按原问卷保留 8 档
吸烟	_SMOKER3	每日吸烟、偶尔吸烟、曾吸烟、从未吸烟
休闲体力活动	_TOTINDA	有、无
水果频次	_FRTLT1	每日至少 1 次、不足每日 1 次
蔬菜频次	_VEGLT1	每日至少 1 次、不足每日 1 次
重度饮酒	_RFDRHV5	否、是
体质指数（BMI）	_BMI5	原值除以 100，单位为 kg/m^2，用于扩展分析

拒答、不确定和无效编码转为缺失。水果、蔬菜频次依官方排除标记处理超出合理范围的回答。表 2列出保留类别，分类变量采用独热编码。

2.4 描述统计与关联分析

采用最终调查权重 _LLCPWT 估计加权比例及 Logistic 回归系数。关联模型同时纳入四项人口学变量和五类行为指标。参照类别为 18 至 24 岁、男性、最低教育类别、最低收入档、每日吸烟、有休闲体力活动、每日至少摄入一次水果、每日至少摄入一次蔬菜及非重度饮酒。回归以 $C = 10^8$ 近似无惩罚拟合，报告 e^{β} 及基于正态近似的 95% 置信区间。

方差估计使用按抽样分层汇总的初级抽样单位（PSU）得分。按州和抽样分层识别各 PSU，样本域外记录对得分的贡献为零。设 A 为加权信息矩阵，U_{hj} 为分层 h 内第 j 个 PSU 的加权得分总和，m_h 为该分层的 PSU 数。夹心协方差估计为

$$\widehat{V} = A^{-1}\left[\sum_{h}\frac{m_h}{m_h-1}\sum_{j}(U_{hj}-\bar{U}_h)(U_{hj}-\bar{U}_h)^{\top}\right]A^{-1}.$$

在 BMI 有效子样本中分别拟合含 BMI 和不含 BMI 的模型，以比较调整变量集合改变后的估计。BMI 以每增加 5 kg/m^2 计。

2.5 分类模型及评价

使用随机种子 20261108，按结局以 60:20:20 划分训练、验证和测试集（表 3）。人口学 Logistic 回归（LR）使用年龄、性别、教育和收入。行为 LR 在同一基础上加入五类行为。直方图梯度提升模型采用相同九项特征，用于比较模型形式。常数基线使用训练集的加权阳性比例作为所有测试记录的预测概率。

表 3　分层样本划分与用途

数据集	未加权人数	用途
训练集	184,609	拟合编码器和模型
验证集	61,537	选择分类阈值
测试集	61,537	评价固定模型

编码器和模型在训练集拟合，使用均值标准化的调查权重。LR 的正则化参数为 $C = 1$，迭代上限为 800。梯度提升训练 120 轮，每棵树最多 15 个叶节点，L2 正则系数为 10。模型参数固定后，以验证集最大约登指数选择阈值。

测试集使用调查权重计算 ROC-AUC、平均精确率（AP）、Brier 分数及阈值分类指标。按预测概率十分位分箱绘制校准图。对同一测试集个体记录进行 150 次配对 Bootstrap 重抽，以 ROC-AUC 差值的第 2.5 和第 97.5 百分位描述重抽稳定性。该区间基于个体重抽，与关联模型的复杂抽样置信区间对应不同的方差估计方法。

3　结果

3.1　样本构成与缺失

429,360 条结局明确且权重有效的记录中，307,683 条进入主分析，占 71.66%。家庭收入、蔬菜频次和水果频次的缺失比例最高，分别为 17.96%、11.60% 和 9.94%（图 1）。纳入者与因特征缺失排除者的加权自报糖尿病比例分别为 10.89% 和 10.51%。表 4呈现按结局分组的特征，图 2展示各年龄组的结局比例。

表 4　按糖尿病状态分组的样本特征（加权构成比，%）

特征	总体	未报告确诊	自报确诊
年龄 ≥65 岁	18.2	15.5	39.9
女性	50.1	50.3	48.2
每日吸烟	11.5	11.6	10.7
无休闲体力活动	25.0	23.4	37.5
水果摄入不足每日 1 次	40.4	40.0	43.6
蔬菜摄入不足每日 1 次	21.5	21.0	25.9
重度饮酒	6.2	6.7	2.8

注：构成比分母为各组加权总数。三组未加权样本数依次为 307,683、267,062 和 40,621。

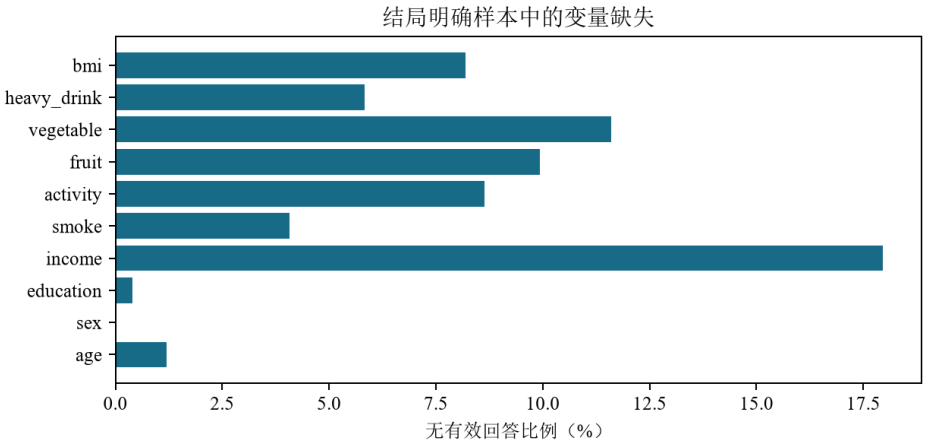


图 1　结局明确且权重有效样本的变量缺失比例。各变量缺失可以重叠。

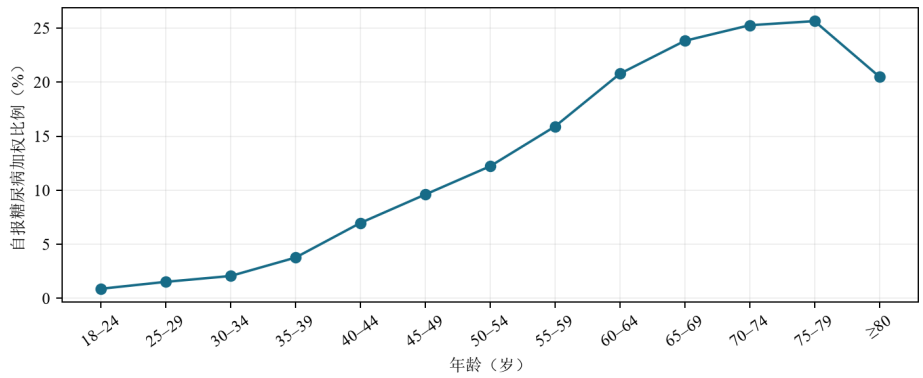


图 2　完整案例中各年龄组的加权自报糖尿病比例。

3.2　健康行为与自报糖尿病的调整后关联

无休闲体力活动与更高的自报糖尿病优势相关（调整后 OR 为 1.427（1.358—1.500））。水果和蔬菜摄入不足每日一次的 OR 分别为 1.118 和 1.095。以每日吸烟者为参照，其余三组的 OR 均大于 1。重度饮酒的 OR 为 0.467（表 5、图 3）。

表 5　健康行为与自报糖尿病状态的调整后关联

比较	调整后 OR（95% CI）
偶尔吸烟 / 每日吸烟	1.151（1.007—1.315）
曾吸烟 / 每日吸烟	1.457（1.346—1.578）
从未吸烟 / 每日吸烟	1.205（1.114—1.303）
无运动 / 有运动	1.427（1.358—1.500）
水果不足每日一次 / 至少一次	1.118（1.063—1.175）
蔬菜不足每日一次 / 至少一次	1.095（1.034—1.160）
重度饮酒 / 非重度饮酒	0.467（0.403—0.541）

注：OR 为优势比，CI 为置信区间。模型同时调整人口学变量及其余行为变量。

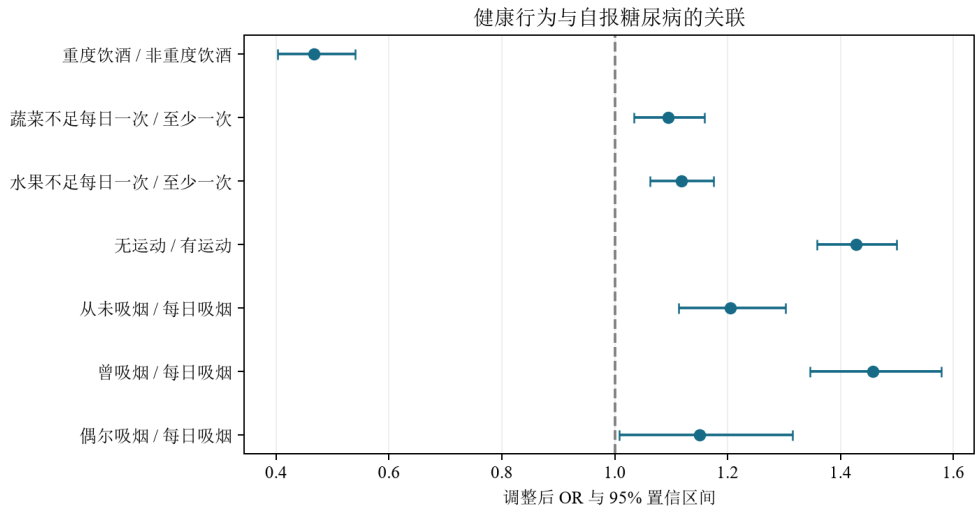


图 3　调整后优势比及 95% 置信区间。区间采用分层 PSU 夹心方差估计。

3.3　BMI 扩展分析

在 295,254 名 BMI 有效受访者中，纳入 BMI 后，无休闲体力活动的 OR 由 1.428 降至 1.240，水果频次的关联也有所减弱（表 6）。BMI 每增加 5 kg/m^2 的 OR 为 1.521（1.493—1.551）。

表 6　同一 BMI 有效子样本中的关联估计比较

比较	未纳入 BMI 的 OR	纳入 BMI 的 OR
无运动 / 有运动	1.428（1.358—1.503）	1.240（1.176—1.307）
水果不足每日一次 / 至少一次	1.124（1.068—1.183）	1.065（1.010—1.123）
蔬菜不足每日一次 / 至少一次	1.085（1.023—1.150）	1.092（1.028—1.161）

注：括号内为 95% 置信区间。

3.4　分类性能与阈值表现

在 61,537 名测试受访者中，纳入行为指标后，LR 的加权 ROC-AUC 增加 0.0076，AP 增加 0.0176，Brier 分数降低 0.0009。梯度提升的 ROC-AUC 与行为 LR 相近，AP 低 0.0050（表 7、图 4）。图 5进一步呈现各模型的分箱校准表现。

表 7　模型在留出测试集上的加权分类表现

模型	ROC-AUC	AP	Brier 分数
常数基线	0.5000	0.1059	0.0947
人口学 LR	0.7763	0.2600	0.0856
人口学与行为 LR	0.7839	0.2776	0.0847
人口学与行为梯度提升	0.7838	0.2726	0.0848

注：AP 为平均精确率。ROC-AUC 和 AP 越高越好，Brier 分数越低越好。

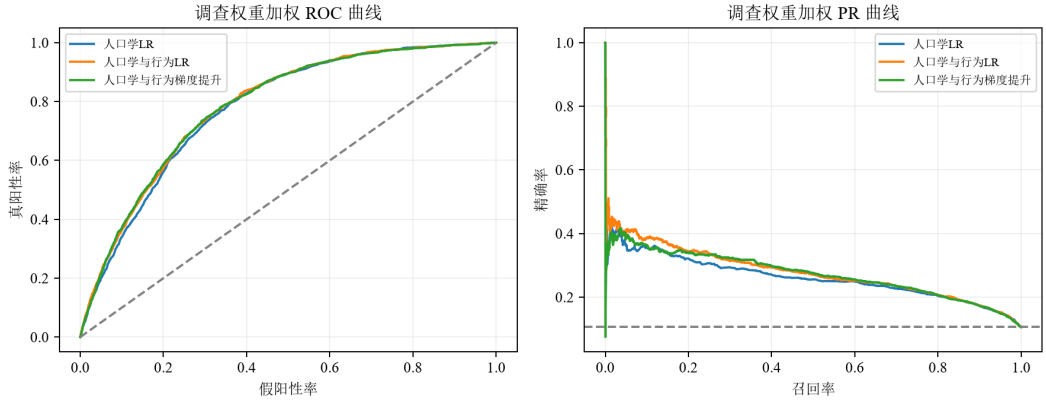


图 4　测试集加权 ROC 与 PR 曲线。PR 图的水平虚线表示测试集加权阳性比例。

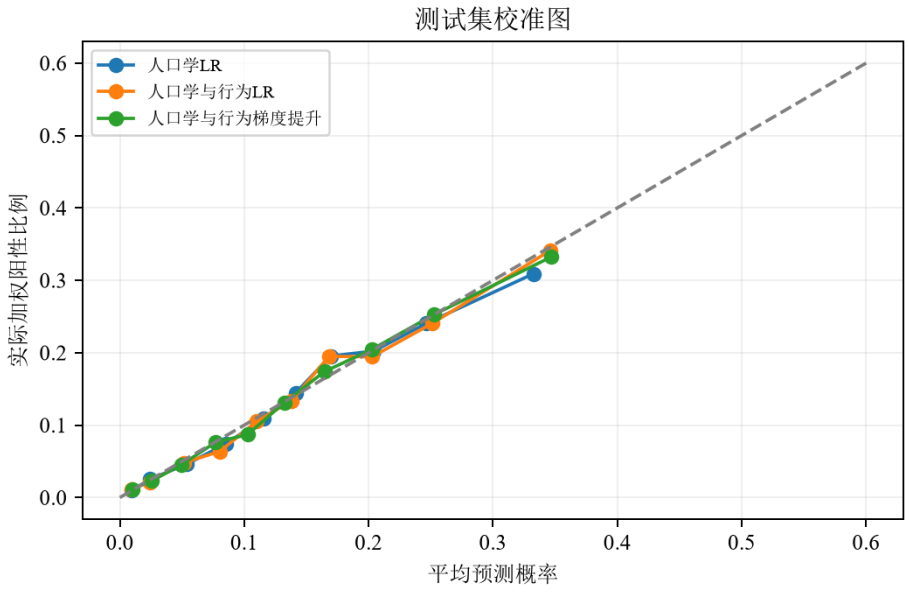


图 5　测试集的分箱校准曲线。各点对应组内加权平均预测概率及实际阳性比例。

行为 LR 在验证集选定阈值下的测试集灵敏度为 78.1%，特异度为 65.9%，阳性预测值为 21.4%（表 8）。按测试集调查权重折合每 1,000 名受访者，约有 305 例误报和 23 例漏判。

表 8　验证集阈值对应的加权测试集分类指标

模型	阈值	灵敏度	特异度	阳性预测值
人口学 LR	0.1147	0.778	0.651	0.209
行为 LR	0.1154	0.781	0.659	0.214
梯度提升	0.1267	0.738	0.702	0.227

注：阈值显示至四位小数，测试评价使用未舍入的阈值。

4　讨论

4.1　主要发现及解释

无休闲体力活动的关联幅度高于果蔬频次指标，加入 BMI 后仍保持正向关联。该方向与既有体力活动研究一致[1]。本研究的 OR 刻画当前或近期行为与既往自报确诊的横断面关联。确诊后的戒烟、饮酒减少或活动变化会改变受访者的行为分布，解释吸烟和饮酒的估计方向时需考虑这一时间顺序。

人口学模型已有一定的区分能力，五类行为指标在此基础上增加了分类信息。行为 LR 与同特征的梯度提升表现接近。在验证集选定的阈值下，行为 LR 识别出 78.1% 的自报阳性，预测阳性中有 21.4% 为自报确诊者。将区分指标与概率表现、误报及漏判并列，可明确模型在同年度调查样本中的分类代价。

4.2　局限性

结局基于自报确诊，涵盖不同糖尿病类型，受诊断机会影响。横断面数据难以确定暴露与确诊的先后顺序。完整案例筛选排除了约 28% 的结局明确记录，调查权重未针对这一筛选重新校准，关联和性能估计可能受缺失选择影响。分类结果来自 2015 年样本内部测试，跨年度或跨地区应用需要独立验证。

5　结论

在 BRFSS 2015 完整案例中，无休闲体力活动和较低果蔬摄入频次与较高的自报糖尿病优势相关。纳入五类行为指标使人口学模型的加权 ROC-AUC 由 0.7763 提高至 0.7839，量化了行为信息对同年度自报状态分类的补充价值。

数据与代码可用性

BRFSS 2015 原始数据由 CDC 公开提供[2]。项目网页提供分析代码、关联系数、模型评价和复现说明。随机种子、数据文件哈希及软件版本随分析材料记录。

参考文献

[1] Hu FB, Sigal RJ, Rich-Edwards JW, et al. Walking compared with vigorous physical activity and risk of type 2 diabetes in women: a prospective study. JAMA. 1999, 282(15):1433–1439. doi:10.1001/jama.282.15.1433.

[2] Centers for Disease Control and Prevention. 2015 BRFSS Survey Data and Documentation [DB/OL]. [2026-11-09]. CDC BRFSS annual data.

[3] Centers for Disease Control and Prevention. Behavioral Risk Factor Surveillance System Overview: BRFSS 2015 [R/OL]. [2026-11-09]. BRFSS 2015 overview.

[4] von Elm E, Altman DG, Egger M, et al. The STROBE statement: guidelines for reporting observational studies. Lancet. 2007, 370(9596):1453–1457. doi:10.1016/S0140-6736(07)61602-X.

[5] Collins GS, Moons KGM, Dhiman P, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. BMJ. 2024, 385:e078378. doi:10.1136/bmj-2023-078378.

[6] Centers for Disease Control and Prevention. BRFSS 2015 Codebook Report [R/OL]. [2026-11-09]. BRFSS 2015 codebook.

[7] Centers for Disease Control and Prevention. BRFSS 2015 Summary Matrix of Calculated Variables [R/OL]. [2026-11-09]. Calculated variables.